

Avaliação Formativa III

Data: 10/06/2026

Alunos:

1. 424431 - Guilherme Smith Dansiguer Rodrigues
2. xxxxxx - Amanda Caroline Furquim

Campus: Chapecó

Curso/Matriz: 41 - Sistemas de Informação/11

Componente(s) curricular(es): 34945 - Inteligência Artificial e Sistemas Inteligentes

Professor: 267645 - Jacson Luiz Matte

Nr. créditos/Carga Horária: 4/80

Período letivo: 2026/1

1. Introdução

Este trabalho tem como objetivo aplicar e comparar os algoritmos Regressão Linear Múltipla (RLM), K-Nearest Neighbors (KNN), Multi-Layer Perceptron (MLP) e Naive Bayes utilizando a biblioteca Scikit-Learn em Python.

Foi utilizado o Student Performance Dataset, disponibilizado pela UCI Machine Learning Repository, contendo dados reais de estudantes do ensino secundário português nas disciplinas de Matemática e Língua Portuguesa. O objetivo da predição foi identificar se um estudante seria aprovado ou reprovado com base nas variáveis disponíveis no dataset, como hábitos de estudo, características familiares, contexto social e histórico escolar.

O estudo busca avaliar o desempenho dos modelos e identificar qual apresenta melhor capacidade preditiva para prever a aprovação dos estudantes, representada pela classificação da nota final (G3) em aprovado ou reprovado. Sendo G3 ≥ 10 aprovado

2. Base de Dados

2.1 Descrição

O dataset utilizado é o Student Performance Dataset, disponibilizado pela UCI Machine Learning Repository. Para aumentar a quantidade de registros disponíveis para treinamento e avaliação dos modelos, foram utilizados os conjuntos de dados referentes às disciplinas de Matemática (`student-mat.csv`) e Língua Portuguesa (`student-por.csv`), que possuem a mesma estrutura de atributos.

O conjunto de dados combinado possui aproximadamente 1.044 registros e 33 atributos originais, contendo informações demográficas, familiares, sociais e acadêmicas dos estudantes.

Variáveis Numéricas

1. age
2. Medu
3. Fedu
4. traveltime
5. studytime
6. failures
7. famrel
8. freetime
9. goout
10. Dalc
11. Walc
12. health
13. absences
14. G1
15. G2
16. G3

Variáveis Categóricas

1. school
2. sex

3. address
4. famsize
5. Pstatus
6. Mjob
7. Fjob
8. reason
9. guardian
10. schoolsup
11. famsup
12. paid
13. activities
14. nursery
15. higher
16. internet
17. romantic

Além dessas variáveis, foi adicionada a coluna **subject**, utilizada para identificar a disciplina de origem do registro (Matemática ou Língua Portuguesa).

2.2 Qualidade dos dados

O conjunto de dados apresentou boa qualidade para aplicação de técnicas de aprendizado de máquina. Não foram identificados valores nulos ou ausentes em nenhuma das variáveis analisadas, permitindo a utilização integral dos registros disponíveis. Os tipos de dados mostraram-se compatíveis com a natureza de cada atributo, contendo variáveis numéricas, categóricas e ordinais adequadamente definidas.

Durante a análise exploratória, verificou-se a existência de observações classificadas como outliers pelo método do Intervalo Interquartil (IQR), principalmente na variável **absences**. Entretanto, esses valores representam situações plausíveis dentro do contexto educacional analisado e não indicam erros de coleta ou inconsistências nos registros, motivo pelo qual foram mantidos na base de dados.

As variáveis relacionadas ao desempenho acadêmico (G1, G2 e G3) apresentaram distribuições relativamente equilibradas e próximas de uma distribuição normal. Já a variável **absences** apresentou forte assimetria positiva, com concentração de estudantes com poucas faltas e pequena quantidade de casos com elevado número de ausências.

De modo geral, o dataset mostrou-se consistente, sem problemas relevantes de qualidade de dados e adequado para as etapas de pré-processamento, transformação de atributos e treinamento dos modelos de aprendizado de máquina propostos neste trabalho.

3. Análise Exploratória de Dados (EDA)

3.1 Estatísticas numéricas

Foram analisadas estatísticas descritivas das variáveis numéricas do dataset, incluindo média (mean), desvio padrão (std), valores mínimos e máximos, além dos quartis (25%, 50% e 75%). As variáveis relacionadas ao desempenho acadêmico (G1, G2 e G3) apresentaram médias próximas de suas medianas, indicando distribuições relativamente equilibradas e baixa influência de valores extremos. As médias observadas foram de 11,21 para G1, 11,25 para G2 e 11,34 para G3, em uma escala de 0 a 20 pontos. A variável idade (age) apresentou média de 16,73 anos e baixa variabilidade, enquanto a variável absences apresentou média de 4,43 faltas e valor máximo de 75, sugerindo a existência de estudantes com quantidades significativamente maiores de faltas em relação ao restante da amostra.

Também foi realizada análise de dispersão numérica utilizando o coeficiente de variação (std / mean), com o objetivo de medir a variabilidade relativa de cada variável. A variável absences apresentou alta dispersão (CV = 140,03%), indicando forte heterogeneidade na quantidade de faltas entre os estudantes. Em contrapartida, a variável age apresentou dispersão muito baixa (CV = 7,41%), demonstrando que a maioria dos estudantes encontra-se concentrada em uma faixa etária semelhante. As variáveis G1, G2 e G3 apresentaram dispersão moderada, com coeficientes de variação de 26,61%, 29,21% e 34,08%, respectivamente, indicando variação razoável no desempenho acadêmico dos alunos analisados.

Para interpretação da dispersão, foi utilizada uma regra prática baseada no coeficiente de variação: valores inferiores a 10% foram classificados como dispersão muito baixa; entre 10% e 20%, baixa; entre 20% e 40%, moderada; e superiores a 40%, alta dispersão. Essa classificação permitiu identificar quais

variáveis apresentavam comportamento mais homogêneo e quais possuíam maior variabilidade dentro da população estudada.

Especificamente em relação à nota final dos estudantes (G3), observou-se média de 11,34 pontos, mediana de 11,00 e desvio padrão de 3,86. Os quartis indicaram que 50% dos estudantes obtiveram notas entre 10 e 14 pontos, sugerindo concentração dos resultados em torno da faixa de aprovação. A proximidade entre média e mediana reforça a hipótese de uma distribuição relativamente equilibrada, sem influência excessiva de valores extremos sobre a nota final.

3.2 Estatísticas categóricas

No que se refere à escolaridade materna, observou-se predominância de mães com ensino superior completo (29,31%), seguida por escolaridade entre o 5º e o 9º ano do ensino fundamental (27,68%) e ensino secundário ou médio (22,80%). Apenas 0,86% das mães não possuíam escolarização formal. Para a escolaridade paterna, a categoria mais frequente foi entre o 5º e o 9º ano do ensino fundamental (31,03%), seguida pelo ensino primário (24,52%), ensino secundário (22,13%) e ensino superior (21,46%). Assim como nas mães, apenas 0,86% dos pais não possuíam escolarização formal.

Em relação ao tempo de deslocamento entre residência e escola, a maioria dos estudantes (59,67%) necessitava de menos de 15 minutos para chegar à instituição de ensino. Outros 30,65% realizavam trajetos entre 15 e 30 minutos, enquanto apenas 9,68% precisavam de mais de 30 minutos de deslocamento.

Quanto ao tempo semanal dedicado aos estudos, a maior parcela dos estudantes (48,18%) estudava entre duas e cinco horas por semana. Além disso, 30,36% estudavam menos de duas horas semanais, enquanto apenas 21,46% dedicavam mais de cinco horas por semana aos estudos.

A análise do histórico de reprovações revelou que 82,47% dos estudantes nunca haviam repetido de ano. Entre aqueles com histórico de reprovação, 11,49% registraram uma reprovação anterior, 3,16% duas reprovações e 2,87% três ou mais reprovações.

A qualidade das relações familiares apresentou resultados predominantemente positivos. As avaliações “boas” e “excelentes” corresponderam a 49,04% e 27,39% da amostra, respectivamente, totalizando

mais de três quartos dos estudantes. Apenas 7,37% classificaram suas relações familiares como ruins ou muito ruins.

Em relação ao tempo livre após a escola, a categoria mais frequente foi o nível intermediário (39,08%), seguida pelos níveis alto (28,07%) e baixo (16,38%). Os extremos, muito baixo e muito alto, representaram 6,13% e 10,34% da amostra, respectivamente.


Quanto à frequência de saídas com amigos, observou-se predominância dos níveis moderados. O nível intermediário concentrou 32,09% dos estudantes, seguido pelo nível baixo (23,75%) e alto (21,74%). Os níveis extremos representaram parcelas menores da amostra.

O consumo de álcool durante os dias úteis mostrou-se bastante reduzido. Aproximadamente 69,64% dos estudantes relataram consumo muito baixo, enquanto apenas 4,98% indicaram níveis muito altos ou altos de consumo nesse período.

Já o consumo de álcool durante os finais de semana apresentou distribuição mais dispersa. Embora o nível muito baixo ainda tenha sido o mais frequente (38,12%), observou-se aumento significativo das categorias intermediárias e elevadas, indicando maior propensão ao consumo alcoólico nos finais de semana em comparação aos dias úteis.


Por fim, quanto à percepção do estado geral de saúde, a categoria mais frequente foi “muito boa” (37,84%), seguida pela avaliação intermediária (20,59%) e boa (16,67%). As avaliações negativas representaram cerca de um quarto da amostra, sugerindo percepção predominantemente positiva da própria saúde entre os estudantes.

3.3 Matriz de Correlação








Desconsiderando as notas intermediárias (G1 e G2), a variável que apresentou maior correlação com a nota final foi o número de reprovações anteriores (failures), com correlação negativa moderada (-0,38), indicando que estudantes com histórico de reprovação tendem a apresentar menor desempenho acadêmico. Entre os demais fatores, destacaram-se a escolaridade da mãe (0,20), o tempo de estudo semanal (0,16) e a escolaridade do pai (0,16), todas com correlação positiva, sugerindo que níveis mais elevados dessas variáveis estão associados a melhores resultados na nota final

3.4 Boxplots



A análise por boxplot evidenciou baixa dispersão para a variável idade e dispersão elevada para a variável absences, caracterizada por uma cauda longa à direita e presença de diversos outliers. As variáveis de desempenho acadêmico (G1, G2 e G3) apresentaram distribuições semelhantes, com concentração dos valores próximos à mediana e poucos outliers inferiores. Embora o método IQR tenha identificado observações extremas nas variáveis analisadas, optou-se por manter todos os registros, uma vez que os valores observados são compatíveis com o domínio do problema e não indicam erros de coleta ou inconsistências nos dados.

3.5 Distribuições



A análise das distribuições das variáveis numéricas permitiu compreender o comportamento dos dados e identificar possíveis assimetrias, concentrações e valores extremos. As variáveis avaliadas foram idade (age), número de faltas (absences) e as notas dos três períodos letivos (G1, G2 e G3).

A variável idade apresentou distribuição concentrada entre 15 e 18 anos, com predominância de estudantes de 16 e 17 anos. Observou-se uma redução gradual na frequência para idades superiores, sendo raros os registros acima de 19 anos. Esse comportamento é compatível com o perfil esperado de estudantes do ensino médio e reforça a baixa dispersão observada anteriormente.

A variável absences apresentou forte assimetria positiva (cauda à direita), caracterizada por grande concentração de estudantes com poucas faltas e pequena quantidade de alunos com números elevados de ausências. A maior parte dos registros encontra-se abaixo de 10 faltas, enquanto poucos estudantes apresentam valores superiores a 20 faltas, chegando a um máximo de 75. Essa distribuição explica a elevada dispersão observada na análise estatística e a presença de diversos outliers identificados pelo método IQR.

As distribuições das notas G1, G2 e G3 apresentaram comportamento semelhante, aproximando-se de uma distribuição normal. Em todas elas observou-se concentração dos estudantes na faixa intermediária de notas, principalmente entre 9 e 14 pontos, com redução gradual das frequências à medida que os valores se afastam da média. Esse padrão indica que a maioria dos estudantes apresenta desempenho acadêmico moderado, enquanto notas extremamente baixas ou extremamente altas são menos frequentes.

Também foi possível observar pequena concentração de notas iguais a zero nas variáveis G1, G2 e G3. Embora esses valores apareçam como extremos em relação ao restante da distribuição, eles representam situações válidas dentro do contexto educacional analisado, podendo estar associados a reprovações, abandono escolar ou ausência de avaliação.

De modo geral, as distribuições observadas indicam um conjunto de dados consistente e compatível com o domínio do problema. Enquanto a variável absences apresenta comportamento fortemente assimétrico e elevada variabilidade, as variáveis relacionadas ao desempenho acadêmico demonstram distribuição relativamente equilibrada, característica favorável para a aplicação dos modelos de aprendizado de máquina propostos neste trabalho.

4. Pré-processamento dos Dados

4.1 Tratamento de variáveis

- Variáveis categóricas foram convertidas utilizando **One-Hot Encoding**
 - school
 - sex
 - address
 - famsize
 - Pstatus
 - Mjob
 - Fjob
 - reason
 - guardian
 - schoolsup
 - famsup
 - paid
 - activities
 - nursery
 - higher
 - internet
 - romantic
 - subject
- Variáveis numéricas foram padronizadas com **StandardScaler**
 - age
 - absences
 - Medu
 - Fedu
 - traveltime
 - studytime
 - failures
 - famrel
 - freetime
 - goout
 - Dalc
 - Walc
 - health
- Variável alvo
 - **G3**
- Variáveis removidas da modelagem:
 - **G1**

- G2

4.2 Detecção de outliers

A detecção de outliers foi realizada utilizando o método do Intervalo Interquartil (IQR), com foco na variável *absences*, uma vez que as demais variáveis numéricas possuem limites naturais definidos pelo próprio domínio do problema (idade entre 15 e 22 anos e notas entre 0 e 20 pontos). A análise identificou a presença de observações extremas relacionadas ao número de faltas, principalmente em estudantes que apresentavam quantidades significativamente superiores à maior parte da amostra.

Apesar de serem classificados como outliers sob o ponto de vista estatístico, esses registros não foram removidos da base de dados. A decisão foi tomada porque os valores observados são plausíveis dentro do contexto educacional analisado e não representam erros de coleta, digitação ou inconsistências nos dados. Além disso, a remoção dessas observações poderia reduzir a capacidade dos modelos de aprender padrões relacionados a estudantes com comportamentos atípicos, mas reais.

Dessa forma, todos os registros foram mantidos para as etapas posteriores de treinamento e avaliação dos modelos de aprendizado de máquina.

4.3 Separação dos dados

Os dados foram divididos em:

- 80% para treino
- 20% para teste

5. Modelos Utilizados

5.1 Regressão Logística

A Regressão Logística foi implementada utilizando a classe `LogisticRegression` da biblioteca `Scikit-Learn`. O modelo foi configurado com `max_iter=1000`, permitindo até mil iterações durante o

processo de otimização dos coeficientes, e `random_state=42`, garantindo a reprodutibilidade dos resultados. O treinamento foi realizado sobre o conjunto de dados previamente processado, contendo variáveis categóricas transformadas por `One-Hot Encoding` e variáveis numéricas padronizadas com `StandardScaler`.

Após o treinamento, o modelo foi utilizado para realizar previsões sobre o conjunto de teste. A avaliação foi realizada por meio das métricas de acurácia, precisão, sensibilidade (recall) e especificidade, calculadas a partir da matriz de confusão gerada pelo modelo. Também foi utilizado o relatório de classificação (`classification_report`) para obtenção das métricas individuais de cada classe analisada.

5.2 KNN Regressor

O algoritmo K-Nearest Neighbors foi implementado utilizando a classe `KNeighborsClassifier` da biblioteca `Scikit-Learn`. Foram avaliados diferentes valores para o hiperparâmetro `n_neighbors`, correspondentes a $k = 3, 5, 7, 9, 11$ e 15 , com o objetivo de identificar a configuração que apresentasse melhor desempenho. Para cada valor de k foi realizado um treinamento independente utilizando o mesmo conjunto de treinamento previamente preparado.

Após a execução de cada configuração, foram calculadas as métricas de acurácia, precisão, sensibilidade e especificidade. Os resultados foram armazenados em uma estrutura tabular para comparação entre os diferentes valores de k . Além disso, foi gerado um gráfico comparativo contendo a evolução das métricas em função do número de vizinhos considerados pelo algoritmo, permitindo identificar o valor de k mais adequado para o problema estudado.

5.3 MLP Regressor

O modelo MLP foi implementado utilizando a classe `MLPClassifier` da biblioteca `Scikit-Learn`. A arquitetura utilizada foi composta por uma única camada oculta contendo **100 neurônios** (`hidden_layer_sizes=(100,)`). Foi utilizada a função de ativação ReLU (`activation="relu"`), amplamente empregada em redes neurais devido à sua eficiência computacional e capacidade de modelar relações não lineares. O treinamento foi realizado utilizando o otimizador Adam (`solver="adam"`), com

limite máximo de 1000 iterações (`max_iter=1000`) e `random_state=42` para garantir reprodutibilidade.

Após o treinamento da rede neural, o modelo foi utilizado para classificar os registros do conjunto de teste. As previsões geradas foram avaliadas por meio das métricas de acurácia, precisão, sensibilidade e especificidade, além da matriz de confusão e do relatório de classificação. A utilização de uma rede neural permitiu que o modelo aprendesse padrões mais complexos entre as variáveis de entrada quando comparado aos algoritmos mais simples avaliados neste estudo.

5.4 Naive Bayes

O algoritmo Naive Bayes foi implementado por meio da classe `GaussianNB` da biblioteca Scikit-Learn. Essa variante assume que as variáveis numéricas seguem distribuição aproximadamente normal (gaussiana) dentro de cada classe analisada. O modelo foi treinado utilizando o conjunto de dados previamente processado, sem necessidade de configuração adicional de hiperparâmetros, uma vez que a implementação padrão da biblioteca já realiza automaticamente a estimação dos parâmetros estatísticos necessários.

Após o treinamento, foram realizadas previsões sobre o conjunto de teste para classificação dos estudantes aprovados ou reprovados. O desempenho foi avaliado utilizando as métricas de acurácia, precisão, sensibilidade e especificidade, além da matriz de confusão e do relatório de classificação. A simplicidade computacional do Naive Bayes permitiu a construção de um modelo de rápida execução, servindo como importante referência comparativa em relação aos demais algoritmos avaliados.

6. Resultados

6.1 Regressão Logística

```
Regressão Logística
Acurácia: 0.7703
Precisão: 0.8108
Sensibilidade/Recall: 0.9202
Especificidade: 0.2391

Matriz de Confusão:
      Previsto Reprovado  Previsto Aprovado
Real Reprovado           11             35
Real Aprovado            13            150

Relatório de Classificação:
      precision  recall  f1-score  support
Reprovado      0.46    0.24    0.31      46
Aprovado       0.81    0.92    0.86     163

accuracy              0.77     209
macro avg            0.63    0.58    0.59     209
weighted avg         0.73    0.77    0.74     209
```

A Regressão Logística apresentou desempenho satisfatório na identificação de estudantes aprovados, obtendo sensibilidade de 92,02% e precisão de 81,08%. Entretanto, o modelo apresentou baixa capacidade de identificar estudantes reprovados, alcançando especificidade de apenas 23,91%.

Esse comportamento está relacionado ao desbalanceamento da variável alvo, composta majoritariamente por estudantes aprovados, fazendo com que o modelo favoreça previsões da classe majoritária. Como consequência, apesar da acurácia global de 77,03%, o modelo demonstrou limitações na detecção de alunos com risco de reprovação.

6.1.1. Otimização de classes

```
Regressão Logística
Acurácia: 0.7033
Precisão: 0.8582
Sensibilidade/Recall: 0.7423
Especificidade: 0.5652

Matriz de Confusão:
```

	Previsto Reprovado	Previsto Aprovado
Real Reprovado	26	20
Real Aprovado	42	121

```
Relatório de Classificação:
```

	precision	recall	f1-score	support
Reprovado	0.38	0.57	0.46	46
Aprovado	0.86	0.74	0.80	163
accuracy			0.70	209
macro avg	0.62	0.65	0.63	209
weighted avg	0.75	0.70	0.72	209

De:

```
logistic_model = LogisticRegression(
    max_iter=1000,
    random_state=42
)
```

Para:

```
logistic_model = LogisticRegression(
    max_iter=1000,
    class_weight="balanced",
    random_state=42
)
```

A utilização de pesos balanceados reduziu a acurácia geral do modelo de 77% para 70%, porém aumentou significativamente sua capacidade de identificar estudantes reprovados, elevando a especificidade de aproximadamente 24% para 57%.

6.2 KNN Regressor

Resultados KNN					
	k	accuracy	precision	recall	specificity
4	11	0.8086	0.8090	0.9877	0.1739
3	9	0.7990	0.8071	0.9755	0.1739
5	15	0.7990	0.8040	0.9816	0.1522
2	7	0.7847	0.7980	0.9693	0.1304
1	5	0.7751	0.7959	0.9571	0.1304
0	3	0.7751	0.8053	0.9387	0.1957

O algoritmo KNN apresentou acurácia superior à Regressão Logística, alcançando 80,86% com $k=11$. Entretanto, o modelo demonstrou forte tendência em classificar estudantes como aprovados, obtendo sensibilidade de 98,77%, porém especificidade de apenas 17,39%.

Isso indica baixa capacidade de identificação de alunos reprovados, tornando o modelo menos adequado para situações em que a detecção precoce de estudantes em risco de reprovação é um requisito importante.

6.3 MLP Regressor

```
MLP
Acurácia: 0.7847
Precisão: 0.8352
Sensibilidade/Recall: 0.9018
Especificidade: 0.3696

Matriz de Confusão:

                Previsto Reprovado  Previsto Aprovado
Real Reprovado          17           29
Real Aprovado           16          147

Relatório de Classificação:
                precision    recall  f1-score   support

    Reprovado         0.52         0.37         0.43         46
    Aprovado          0.84         0.90         0.87        163

    accuracy                   0.78        209
    macro avg              0.68         0.64         0.65        209
    weighted avg           0.76         0.78         0.77        209
```

O algoritmo MLP apresentou acurácia de 78,47%, valor próximo ao obtido pela Regressão Logística e ligeiramente inferior ao melhor resultado do KNN. O modelo obteve precisão de 83,52% e sensibilidade de 90,18%, demonstrando boa capacidade de identificar estudantes aprovados e mantendo um equilíbrio satisfatório entre acertos e erros de classificação.

Em comparação aos demais modelos avaliados até o momento, o MLP apresentou a melhor capacidade de identificação de estudantes reprovados, alcançando especificidade de 36,96%. Embora esse valor ainda esteja distante do ideal, representa uma melhora significativa em relação à Regressão Logística (23,91%) e ao KNN (17,39%). Dessa forma, o MLP demonstrou maior equilíbrio entre a identificação de alunos aprovados e reprovados, tornando-se o modelo com melhor desempenho geral entre os algoritmos analisados até esta etapa do estudo.

6.4 Naive Bayes

```
Naive Bayes
Acurácia: 0.7560
Precisão: 0.8333
Sensibilidade/Recall: 0.8589
Especificidade: 0.3913

Matriz de Confusão:
      Previsto Reprovado Previsto Aprovado
Real Reprovado      18      28
Real Aprovado      23     140

Relatório de Classificação:
      precision  recall  f1-score  support
Reprovado    0.44    0.39    0.41      46
Aprovado     0.83    0.86    0.85     163

accuracy          0.76     209
macro avg         0.64    0.63    0.63     209
weighted avg      0.75    0.76    0.75     209
```

O algoritmo Naive Bayes apresentou acurácia de 75,60%, precisão de 83,33% e sensibilidade de 85,89%, demonstrando bom desempenho na identificação de estudantes aprovados. Embora tenha obtido resultados inferiores aos do MLP em acurácia e sensibilidade, o modelo manteve desempenho competitivo e mostrou-se capaz de realizar classificações consistentes mesmo assumindo independência entre as variáveis de entrada.

Entre todos os modelos avaliados, o Naive Bayes apresentou a maior especificidade, alcançando 39,13%. Isso significa que foi o algoritmo com melhor capacidade de identificar corretamente estudantes reprovados, acertando 18 dos 46 casos presentes no conjunto de teste. Entretanto, essa melhora na identificação da classe minoritária ocorreu à custa de uma redução na acurácia geral e na taxa de acerto dos estudantes aprovados, fazendo com que o modelo apresentasse desempenho global ligeiramente inferior ao obtido pelo MLP.

7. Discussão dos Resultados

7.1. Sem otimização nenhuma

Comparação Final dos Modelos					
	Modelo	Acurácia	Precisão	Recall	Especificidade
1	KNN (k=11)	0.8086	0.8090	0.9877	0.1739
2	MLP	0.7847	0.8352	0.9018	0.3696
0	Regressão Logística	0.7703	0.8108	0.9202	0.2391
3	Naive Bayes	0.7560	0.8333	0.8589	0.3913

Sem aplicação de técnicas de balanceamento ou otimização de hiperparâmetros, o modelo KNN (k=11) apresentou a maior acurácia (80,86%), seguido pelo MLP (78,47%), Regressão Logística (77,03%) e Naive Bayes (75,60%). Entretanto, a análise das métricas complementares mostrou que todos os modelos apresentaram elevada sensibilidade (recall) e baixa especificidade, indicando maior facilidade em identificar estudantes aprovados do que reprovados.

Esse comportamento pode ser explicado pelo desbalanceamento da variável alvo, composta majoritariamente por estudantes aprovados. Embora o KNN tenha obtido a melhor acurácia, sua especificidade foi a menor entre os modelos (17,39%), enquanto o Naive Bayes apresentou a maior capacidade de identificar reprovados (39,13%). Já o MLP demonstrou o melhor equilíbrio geral entre acurácia, sensibilidade e especificidade, apresentando desempenho intermediário nas diferentes métricas avaliadas.

7.1.Com otimizações

Otimizações:

1. Smote no treino
2. **class_weight="balanced"** na regressão logística

Comparação Final dos Modelos					
	Modelo	Acurácia	Precisão	Recall	Especificidade
2	MLP	0.7703	0.8443	0.8650	0.4348
0	Regressão Logística	0.7033	0.8531	0.7485	0.5435
3	Naive Bayes	0.7033	0.8435	0.7607	0.5000
1	KNN (k=15)	0.5981	0.8624	0.5767	0.6739

Após a aplicação do balanceamento das classes por meio do SMOTE e da utilização de pesos balanceados na Regressão Logística, observou-se uma redução geral da acurácia dos modelos em comparação aos resultados obtidos com os dados originais. Entretanto, houve aumento significativo da especificidade, indicando maior capacidade dos algoritmos em identificar corretamente estudantes reprovados. Esse comportamento era esperado, uma vez que o balanceamento reduz a tendência dos modelos de favorecer a classe majoritária (aprovados).

Nesse cenário, o MLP apresentou a maior acurácia (77,03%) e manteve o melhor equilíbrio entre as métricas avaliadas, combinando elevada sensibilidade (86,50%) com especificidade moderada (43,48%). A Regressão Logística e o Naive Bayes apresentaram acurácia semelhante (70,33%), porém com maior capacidade de identificação da classe minoritária, especialmente a Regressão Logística, que alcançou especificidade de 54,35%. Já o KNN foi o modelo mais impactado pelo balanceamento, apresentando a menor acurácia (59,81%), embora tenha obtido a maior especificidade (67,39%), evidenciando forte aumento na identificação de reprovados em detrimento da classificação correta dos aprovados.

8. Conclusão

Inicialmente, os modelos foram avaliados utilizando os dados originais, sem qualquer técnica de balanceamento ou otimização adicional. Nessa configuração, o KNN (k=11) apresentou a maior acurácia (80,86%), seguido pelo MLP (78,47%), Regressão Logística (77,03%) e Naive Bayes (75,60%). Entretanto, a análise da especificidade revelou que todos os modelos apresentavam dificuldades para identificar estudantes reprovados, favorecendo

fortemente a classe majoritária (aprovados), consequência direta do desbalanceamento existente na variável alvo.

Em seguida, foi avaliada a utilização do parâmetro `class_weight="balanced"` na Regressão Logística. Embora essa abordagem tenha reduzido a acurácia geral do modelo, houve aumento expressivo da especificidade, indicando melhora significativa na identificação da classe minoritária. Os resultados demonstraram que o balanceamento por pesos permitiu ao algoritmo produzir previsões mais equilibradas entre aprovados e reprovados, reduzindo o viés observado na configuração original.

Posteriormente, foi aplicada a técnica SMOTE para balanceamento sintético da base de treinamento. Os experimentos mostraram que o balanceamento aumentou a capacidade dos modelos de reconhecer estudantes reprovados, refletida pelo aumento da especificidade em praticamente todos os algoritmos. Em contrapartida, observou-se redução da acurácia global, comportamento esperado quando o modelo deixa de privilegiar a classe majoritária para aprender padrões de ambas as classes. Entre os modelos avaliados nesse cenário, o MLP apresentou o melhor equilíbrio entre acurácia, recall e especificidade.

Considerando todos os experimentos realizados, conclui-se que o MLP treinado com dados balanceados por SMOTE apresentou o melhor compromisso entre desempenho geral e capacidade de classificação das duas classes. Embora o KNN tenha obtido a maior acurácia nos dados originais, seu desempenho na identificação de estudantes reprovados foi limitado. Dessa forma, para uma aplicação prática cujo objetivo seja auxiliar na identificação de estudantes em risco de reprovação, o MLP com SMOTE mostrou-se a alternativa mais adequada entre os modelos avaliados.

9. Considerações Finais

Este trabalho permitiu aplicar na prática conceitos fundamentais de aprendizado de máquina, incluindo análise exploratória de dados, pré-processamento, balanceamento de classes e avaliação comparativa de diferentes algoritmos de classificação. A utilização de métricas além da acurácia mostrou-se essencial para compreender o comportamento dos modelos diante de um conjunto de dados desbalanceado, evidenciando a

importância de analisar sensibilidade, especificidade e matriz de confusão durante o processo de avaliação.

Embora os resultados obtidos tenham sido satisfatórios, algumas limitações devem ser consideradas. O conjunto de dados utilizado possui quantidade relativamente reduzida de registros e está restrito ao contexto de estudantes do ensino secundário português, o que limita a generalização dos resultados para outras populações. Além disso, apenas os algoritmos propostos na atividade foram avaliados, não sendo exploradas técnicas mais avançadas de modelagem ou otimização de hiperparâmetros.

Como trabalhos futuros, seria interessante avaliar outros algoritmos de classificação, realizar busca sistemática de hiperparâmetros, aplicar técnicas adicionais de engenharia de atributos e utilizar conjuntos de dados maiores e mais diversificados. Também seria possível transformar o modelo selecionado em uma aplicação prática capaz de estimar o risco de reprovação de estudantes a partir de suas características acadêmicas, familiares e sociais.

10. Links e referências

Pasta do drive: [IA - Trabalho Final Drive](#)

Código: [IA - Trabalho Final](#)

Dataset: [Student Performance UCI Machine Learning Repository](#)